

[SYSTEM_DIAGNOSTIC_INITIATED]
// TARGET: GENERATIVE_AI_RELIABILITY

สัจฐานวิทยาของ AI Hallucination

การถอดรหัสแบบจำลองความเสี่ยงทางคณิตศาสตร์
และกลไกการตรวจจับตัวเอง (Self-Verification)




ภาพลวงตาของความน่าจะเป็น (The Illusion of Probability)

Verified Reality

AI Hallucination คืออะไร?

ปรากฏการณ์ที่แบบจำลอง Generative AI สร้างเนื้อหาที่ดูสมเหตุสมผลในเชิงภาษา แต่ "ไม่ถูกต้องตามข้อเท็จจริง" (Factual Error) หรือ "ไม่มีอยู่จริง" (Fabrication)



Linguistic Probability

“

AI ไม่ได้โกหก แต่มันกำลังทำนายลำดับคำที่มีความน่าจะเป็นสูงสุด โดยปราศจากการตรวจสอบความจริงจากฐานความรู้ที่ตายตัว

การวัดระดับความผิดพลาด (The Hallucination Score)


Threat Gauge



4 เสาหลักแห่งความเสี่ยง (Deconstructing the Black Box)


ตัวเร่งความเสี่ยง (Risk Amplifiers)

ตัวลดความเสี่ยง (Risk Mitigators)



Hallucination ไม่ใช่ความล้มเหลวแบบจุดเดียว (Single point of failure) แต่เป็นผลลัพธ์จากการทำงานร่วมกันของ 4 ปัจจัยนี้

แบบจำลองสมการ Tipping Point (The Logistic Model)



+ 8U & + 4C

น้ำหนักเชิงบวก
ดึงระบบเข้าสู่จุดวิกฤต
(ความไม่แน่นอนมีอิทธิพลสูงสุด)

- 3P & - 2B

น้ำหนักเชิงลบ
ช่วยดึงกราฟหนีจากความเสี่ยง
(Prompt และบริบทคือเกราะป้องกัน)




Core Insight: ทำไมต้องเป็น S-Curve? ความเสี่ยงจะสะสมตัวอย่างช้าๆ จนถึง 'จุดวิกฤต' (Tipping Point) ที่โมเดลสับสน ก่อนจะพุ่งทะยานสู่สถานะ Hallucination อย่างรวดเร็ว

พลวัตของความเสี่ยง (Analyzing the Risk Curves)

Axis Definitions

แกน X (U):
ความไม่แน่นอนของข้อมูล
(Data Uncertainty)

แกน Y (H):
ความเสี่ยงที่จะเกิด
ความเสียหาย
Hallucination
(Risk Level)



การวิเคราะห์ 4 สถานการณ์ (Scenario Matrix)

กรณีที่ 1 (Best Case - เส้นสีเขียว)	C ต่ำ + P สูง + B เพียงพอ	ทนทานสูงสุด (ต้องใช้ U สูงมากจึงจะพลาด)
กรณีที่ 2 (เส้นสีดำ)	C สูง + P สูง + B เพียงพอ	ปลอดภัยปานกลาง (แม้คำถามจะซับซ้อน แต่ Prompt ที่ดีช่วยเรียงกราฟไว้ได้)
กรณีที่ 3 (เส้นสีน้ำเงิน)	C ต่ำ + P ต่ำ + B ไม่พอ	เสี่ยงสูง (แม้คำถามง่าย แต่ขาดบริบทและ Prompt แยก)
กรณีที่ 4 (Worst Case - เส้นสีแดง)	C สูง + P ต่ำ + B ไม่พอ	วิกฤต (AI มีโอกาส Hallucinate สูงสุดตั้งแต่วินาทีแรก)



Takeaway: เราไม่สามารถลดความซับซ้อน (C) ของงานได้เสมอไป แต่เราควบคุม Prompt (P) และบริบท (B) **เพื่อเลือกกราฟ** หนีความเสี่ยงได้

เกณฑ์การประเมินและการแทรกแซง (Risk Thresholds)




Engineering Rule: โซนความเสี่ยงปานกลาง (Medium Risk) คือเป้าหมายหลักในการทำ Prompt Engineering และการสร้างกลไกตรวจสอบ

AI สามารถตรวจจับ Hallucination ของตัวเองได้หรือไม่?


จากทฤษฎีความเสี่ยง สู่การทดสอบสมมติฐาน:
หากเราบังคับให้ AI เป็นผู้ตรวจสอบ (Verifier)
เราจะสามารถเพิ่มค่า P และ B แบบอัตโนมัติ
เพื่อลด Hallucination Score ได้จริงหรือไม่?

สถาปัตยกรรมกลไกตรวจสอบตัวเอง (Self-Verification Loop)



ผลกระทบของการตรวจสอบตัวเอง (Impact of Self-Correction)

The Engineering Solution



[SUCCESS METRICS]

30%  12%

รอบแรก (Draft):
อัตราการผิดพลาด (Error Rate) อยู่ที่ 30%

หลังผ่าน Self-Verification:
อัตราความผิดพลาดลดลงเหลือ 12%

Insight: หลักฐานเชิงปริมาณยืนยันว่า
กระบวนการตรวจสอบช่วยกดเส้นกราฟความเสี่ยง
(ลด H Score) ได้อย่างมีนัยสำคัญ

[EDGE CASE FAILURE]


30%  35%

ความล้มเหลวเชิงลึก: ในบางกรณี
อัตราการผิดพลาดพุ่งจาก 30% เป็น 35%
หลังการตรวจสอบ

Diagnosis: หากค่า U (Data Uncertainty)
ของฐานข้อมูล AI ต่ำจนเข้าขั้นวิกฤต
(โมเดลไม่มีข้อมูลนั้นเลยจริงๆ)
การสั่งให้ AI ตรวจสอบตัวเอง จะยิ่งเร่งปฏิกิริยาให้เกิด
Hallucination ซ้อน Hallucination

บทสรุปผู้บริหาร: การควบคุมความเสี่ยง GenAI

The Engineering Solution



1

ความเสี่ยงเป็นสมการ (Risk is Calculable)


Hallucination ไม่ใช่ความผิดพลาดแบบสุ่ม แต่เป็นสมการทางคณิตศาสตร์ระหว่างความไม่แน่นอน (U), ความซับซ้อน (C), Prompt ภาพ Prompt (P), และบริบท (B)



2

การเลื่อนจุดวิกฤต (Shifting the Tipping Point)

กราฟ Logistic ชี้ให้เห็นว่า
แม้งานจะซับซ้อน แต่เราสามารถ
ชะลอจุดล้มเหลวของ AI
ได้ด้วยกำรวิศวกรรม Prompt
และเพิ่ม Context เสมอ



3

กลไกตรวจสอบเป็นสิ่งจำเป็น (Systemic Verification)

การวางระบบ Self-Verification Loop คือการสร้างเกราะป้องกันอัตโนมัติ ช่วยลดระดับความผิดพลาด (Hallucination Score) จากความเสี่ยงปานกลางให้อยู่ในเกณฑ์ที่ควบคุมได้



[DIAGNOSTIC COMPLETE] // FRAMEWORK_READY_FOR_DEPLOYMENT